1. **Efek Regularisasi pada batch Normalization**

Batch Normalization menormalisasi aktivasi lapisan tersembunyi menggunakan rata-rata dan varians yang dihitung secara dinamis berdasarkan mini-batch tertentu, bukan keseluruhan populasi data. Karena mini-batch bersifat stokastik dan bervariasi antariterasi, nilai statistik tersebut juga turut berfluktuasi. Fluktuasi acak ini secara tidak langsung menyuntikkan derau (*noise*) ke dalam jaringan, yang berfungsi layaknya regularisasi ringan dan seringkali mengeliminasi kebutuhan penggunaan Dropout. Mekanisme ini memaksa model agar tidak terlalu bergantung pada aktivasi spesifik dari sampel tunggal, sehingga efektif menekan *overfitting*. Kendati demikian, asumsi penghilangan Dropout ini tidak berlaku apabila ukuran mini-batch terlalu kecil, karena estimasi varians yang dihasilkan menjadi sangat tidak stabil dan memicu instabilitas pelatihan.

Rujukan materi merujuk pada Slide 6–8 serta literatur Ioffe & Szegedy (2015).

2. **Degradasi jaringan dalam dan Formulasi residual**

Pada plain CNN yang sangat dalam, penambahan lapisan secara paradoks justru menurunkan akurasi pelatihan, meskipun secara teoritis model yang lebih dalam minimal dapat menyamai performa model dangkal melalui fungsi identitas. Masalah degradasi ini timbul karena lapisan konvolusi non-linier kesulitan mempelajari fungsi identitas secara murni. Kehadiran *skip connection* mengatasi hambatan tersebut dengan merumuskan ulang pemetaan lapisan menjadi $y = F(x) + x$**.** Saat propagasi balik dilakukan, formulasi penambahan ini menghasilkan komponen turunan tambahan bernilai satu pada jalur gradien. Aliran gradien dapat langsung menembus jalur pintas tanpa tereduksi secara drastis, sehingga fenomena *vanishing gradient* yang menghambat pelatihan jaringan dalam berhasil dimitigasi dengan optimal.

Rujukan materi bersumber dari Slide 10–12 serta literatur He et al. (2016).

3. **Feature extraction vs Fine-Tuning**

Pendekatan *Feature Extraction* dan *Fine-Tuning* memiliki karakteristik yang kontras jika ditinjau dari empat dimensi utama. Pertama, *Feature Extraction* hanya memperbarui parameter pada *classifier head* dengan membekukan seluruh lapisan *backbone*, sedangkan *Fine-Tuning* membuka dan memperbarui sebagian atau seluruh bobot lapisan dalam. Kedua, pendekatan ekstraksi fitur sangat ideal untuk volume data latih yang sangat terbatas, sementara *fine-tuning* membutuhkan data lebih besar agar terhindar dari *overfitting*. Ketiga, beban komputasi dan memori per *epoch* jauh lebih ringan pada ekstraksi fitur karena komputasi *backward pass* terbatas pada lapisan akhir. Keempat, risiko *destructive gradient updates* sangat tinggi pada *fine-tuning* jika laju pembelajaran awal tidak dikontrol dengan hati-hati. Keduanya dapat dipilih secara adaptif berdasarkan ketersediaan data target dan kemiripan domain.

Rujukan materi mencakup Slide 14–16 serta literatur Yosinski et al. (2014).

4. **Kaidah penerapan Data Augmentation**

Pipeline data augmentation secara metodologis hanya diaktifkan pada *train set* guna mensimulasikan keragaman data buatan dan memperkecil *generalization gap*, namun harus dinonaktifkan pada *validation* serta *test set*. Penonaktifkan pada data evaluasi krusial dilakukan agar metrik performa model bersifat objektif, konsisten, serta mencerminkan distribusi data dunia nyata secara akurat. Dalam konteks klasifikasi ras hewan peliharaan, salah satu contoh transformasi citra yang tidak layak diterapkan adalah pembalikan vertikal (*vertical flip*). Transformasi ini melanggar invariansi semantik label karena mengubah orientasi anatomi alami hewan secara tidak wajar, di mana posisi kepala menjadi di bawah, sehingga berpotensi menyesatkan proses interpretasi fitur visual oleh model.

Rujukan materi bersumber dari Slide 20, 21, dan 23 serta literatur Shorten & Khoshgoftaar (2019).

5. **Mitigasi Catastrophic Forgetting**

Catastrophic forgetting terjadi ketika model *pre-trained* beradaptasi secara terlalu agresif pada dataset target baru, sehingga pembaruan bobot besar-besaran menimpa dan merusak representasi fitur generik berharga yang sebelumnya telah dipelajari dari dataset sumber. Untuk menanggulangi hilangnya memori bawaan tersebut, dua strategi mitigasi konkret dapat diterapkan. Pertama, *differential learning rate* diterapkan untuk memberikan laju pembelajaran yang sangat kecil pada lapisan awal dan laju lebih tinggi pada lapisan akhir. Kedua, *gradual unfreezing* dilakukan dengan membuka lapisan secara bertahap mulai dari bagian terluar. Alasan teoritis di balik efektivitas strategi ini adalah kemampuannya dalam menjaga stabilitas parameter inti pengekstraksi fitur sekaligus mempertahankan plastisitas model terhadap tugas baru.

Rujukan materi mencakup Slide 28–29 serta literatur Kirkpatrick et al. (2017).