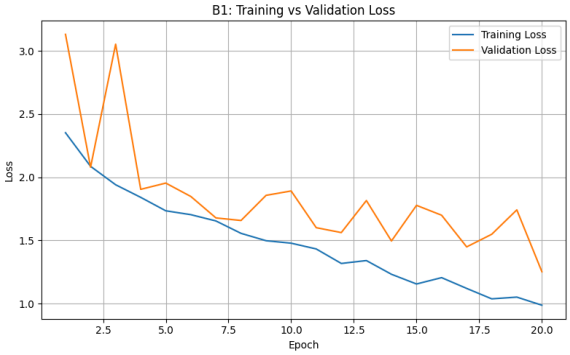
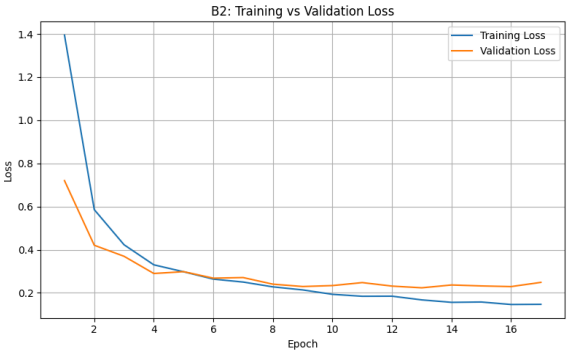
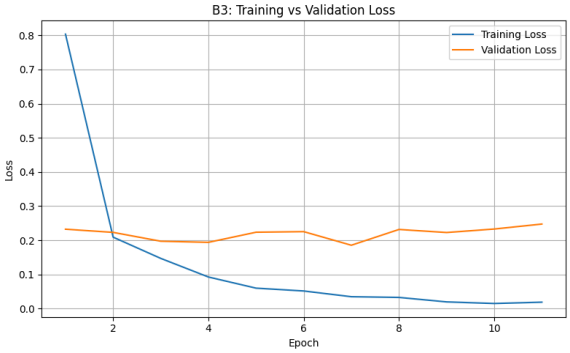
1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Kondisi	Trainable Params	Learning Rates	Epochs	Waktu Latih	Accuracy	F1
B1	11.181.642	1e-3	20	5m 43s	0.575758	0.564536
B2	5.130	1e-3	17	3m 49s	0.929293	0.929452
B3	8.398.858	L4 : 1e-4 CF : 1e-3	11	2m 28s	0.962963	0.963273
B4	8.398.858	L4 : 1e-4 CF : 1e-3	8	1m 13s	0.949495	0.949859
B5	12.810	CF : 1e-3	20	4m 35s	0.929293	0.929116







2. Pembahasan Analisis Komparatif

a. Kurva *loss* pada eksperimen B1 memperlihatkan ketidakstabilan (*instability*) yang sangat tinggi, di mana kurva validasi berfluktuasi secara liar tanpa pola penurunan yang konsisten terhadap epoch. Hal ini terjadi karena pelatihan model dari nol pada data terbatas menyebabkan *overfitting* parah dan kesulitan generalisasi, yang dibuktikan dengan nilai *loss* validasi yang tetap tinggi (di atas 1,2) meskipun *loss* pelatihan menurun terus menerus hingga menyentuh angka 1,0. Model gagal menangkap representasi fitur yang stabil, mencerminkan kelemahan mendasar dari pelatihan *from scratch* tanpa bantuan *pretrained weights*.

b. Kurva *loss* pada eksperimen B2 menunjukkan konvergensi yang jauh lebih stabil dan mulus dibandingkan B1. *Loss* pelatihan dan validasi bergerak turun secara konsisten pada awal epoch dan beriringan rapat di sekitar angka 0,2 hingga 0,25. Stabilitas ini menunjukkan bahwa pemanfaatan *pretrained backbone* (dengan membekukan seluruh lapisan selain *classifier*) sangat efektif mencegah *overfitting*, menghasilkan lompatan performa yang masif, serta memberikan proses generalisasi yang handal meskipun jumlah parameter yang dilatih sangat minim.

c. Kurva *loss* pada eksperimen B3 menunjukkan performa optimal dengan konvergensi tercepat dan tingkat akurasi tertinggi di antara ketiganya. *Loss* pelatihan turun sangat tajam mendekati nol, sementara *loss* validasi tetap terjaga rendah secara stabil di kisaran 0,18 hingga 0,25 berkat kombinasi *differential learning rate* pada *layer 4* dan *classifier*. Strategi pembukaan lapisan secara selektif ini memberikan fleksibilitas adaptasi domain yang optimal tanpa merusak representasi fitur bawaan, menghasilkan kurva generalisasi yang paling superior.

3. Failure Analysis



Dari hasil diatas, dapat dilihat bahwa ada beberapa class yang tertukar, contohnya Ras Kucing Abyssinian dan Bengal, lalu untuk Ras Anjing ada Pit Bull Terrier dan Boxer yang tertukar. Meskipun hasil *confidence* prediksi tinggi, tapi itu tidak mengartikan bahwa hasil prediksi tersebut benar 100%.

4. Rekomendasi Rekayasa dan Batasan Eksperimen

Untuk meningkatkan performa model, pengembangan selanjutnya dapat dilakukan dengan menambah variasi dan jumlah data pada kelas yang sering tertukar, menerapkan augmentasi yang lebih sesuai, serta melakukan analisis confusion matrix untuk mengidentifikasi pasangan kelas dengan kesalahan terbanyak. Fine-tuning pada lebih banyak layer atau mencoba arsitektur lain, seperti EfficientNet-B0, juga dapat dievaluasi melalui eksperimen terkontrol. Namun, eksperimen ini terbatas pada 10 kelas terpilih dari dataset Oxford-IIIT Pet, sehingga hasilnya belum tentu berlaku untuk semua ras kucing dan anjing. Selain itu, performa model dapat dipengaruhi oleh jumlah data, variasi pencahayaan, latar belakang, pose hewan, serta kemiripan antar kelas.

5. Pernyataan Penggunaan AI:

a. Model : Google Gemini
Ruang Lingkup : Saya menggunakan AI untuk merangkum materi-materi dari slide yang telah ada, dan saya juga menggunakan AI juga untuk lebih memahami tujuan dari eksperimen ini.

b. Model : ChatGPT-6 Free
Ruang Lingkup : Saya menggunakan AI untuk memberikan saya panduan, step by step, serta penjelasan code untuk setiap bagian sehingga saya lebih mudah mengerti

Untuk Referensi terkait hasil eksperimen saya, saya juga sempat bertanya kepada teman-teman yang lain terkait hasil mereka. Hasilnya adalah adanya perbedaan hasil eksperimen, meskipun perbedaan tersebut tidak terlalu jauh